

MOwNiT

April 4, 2024

1 Laboratorium 03

1.1 Interpolacja

Iga Antonik, Helena Szczepanowska

2 Zadanie 1

Populacja Stanów Zjednoczonych na przestrzeni lat przedstawiała się następująco: | Rok | Populacja
| |——|—————| | 1900 | 76,212,168 | | 1910 | 92,228,496 | | 1920 | 106,021,537 | | 1930 |
123,202,624 | | 1940 | 132,164,569 | | 1950 | 151,325,798 | | 1960 | 179,323,175 | | 1970 | 203,302,031
| | 1980 | 226,542,199 |

Istnieje dokładnie jeden wielomian ósmego stopnia, który interpoluje powyższe dziewięć punktów, natomiast sam wielomian może być reprezentowany na różne sposoby.

Rozważamy następujące zbiory funkcji bazowych $j(t)$, $j = 1, \dots, 9$:

$$\varphi_j(t) = t^{j-1} \quad (1)$$

$$\varphi_j(t) = (t - 1900)^{j-1} \quad (2)$$

$$\varphi_j(t) = (t - 1940)^{j-1} \quad (3)$$

$$\varphi_j(t) = ((t - 1940)/40)^{j-1} \quad (4)$$

- Dla każdego z czterech zbiorów funkcji bazowych utwórz macierz Vandermonde'a.
- Oblicz współczynnik uwarunkowania każdej z powyższych macierzy, używając funkcji `numpy.linalg.cond`.
- Używając najlepiej uwarunkowanej bazy wielomianów, znajdź współczynniki wielomianu interpolacyjnego dla danych z zadania. Narysuj wielomian interpolacyjny. W tym celu użyj schematu Hornera i oblicz na przedziale $[1900, 1990]$ wartości wielomianu w odstępach jednorocznych. Na wykresie umieść także węzły interpolacji.
- Dokonaj ekstrapolacji wielomianu do roku 1990. Porównaj otrzymaną wartość z prawdziwą wartością dla roku 1990, wynoszącą 248 709 873. Ile wynosi błąd względny ekstrapolacji dla roku 1990?
- Wyznacz wielomian interpolacyjny Lagrange'a na podstawie 9 węzłów interpolacji podanych w zadaniu. Oblicz wartości wielomianu w odstępach jednorocznych.

- (f) Wyznacz wielomian interpolacyjny Newtona na podstawie tych samych węzłów interpolacji i oblicz wartości wielomianu w odstępach jednorocznych.
- (g) Zaokrąglaj dane podane w tabeli do jednego miliona. Na podstawie takich danych wyznacz wielomian interpolacyjny ósmego stopnia, używając najlepiej uwarunkowanej bazy z podpunktu (c). Porównaj wyznaczone współczynniki z współczynnikami obliczonymi w podpunkcie (c). Wyjaśnij otrzymany wynik.

2.1 Rozwiązanie

2.1.1 Biblioteki

```
[ ]: import numpy as np
import matplotlib.pyplot as plt
```

Dane:

```
[ ]: years = np.array([1900, 1910, 1920, 1930, 1940, 1950, 1960, 1970, 1980])
population = np.array([76212168, 92228496, 106021537, 123202624, 132164569,
↪ 151325798, 179323175, 203302031, 226542199])

j = np.arange(9)
```

Funkcje bazowe:

```
[ ]: def phi1(t,i):
    return t ** i

def phi2(t,i):
    return (t - 1900) ** i

def phi3(t,i):
    return (t - 1940) ** i

def phi4(t,i):
    return ((t - 1940) / 40) ** i

T_phi = [phi1,phi2,phi3,phi4]
```

Tworzenie macierzy Vandermonde'a:

```
[ ]: V1 = np.array([[phi1(t,i) for i in j] for t in years ])
V2 = np.array([[phi2(t,i) for i in j] for t in years ])
V3 = np.array([[phi3(t,i) for i in j] for t in years ])
V4 = np.array([[phi4(t,i) for i in j] for t in years ])

T_V = [V1,V2,V3,V4]
```

Wyliczanie współczynników uwarunkowania:

```
[ ]: cond_V1 = np.linalg.cond(V1)
cond_V2 = np.linalg.cond(V2)
cond_V3 = np.linalg.cond(V3)
cond_V4 = np.linalg.cond(V4)

print("Współczynniki uwarunkowania:")
print("(1) ", cond_V1)
print("(2) ", cond_V2)
print("(3) ", cond_V3)
print("(4) ", cond_V4)
```

Współczynniki uwarunkowania:

```
(1) 4.044398246625838e+26
(2) 6211148482504961.0
(3) 9315536040586.037
(4) 1605.4437004786669
```

Wyznaczenie najmniejszego współczynnika:

```
[ ]: T_cond = [cond_V1, cond_V2, cond_V3, cond_V4]
min_cond = min(T_cond)
```

Wyliczanie wielomianu interpolacyjnego:


```
[ ]: best_V = T_V[T_cond.index(min_cond)]
phi = T_phi[T_cond.index(min_cond)]

B = lambda t: np.array([phi(t,i) for i in j]) # B - baza
coefficients = np.linalg.solve(best_V, population.T) # A - współczynniki
    ↪ wielomianu interpolacyjnego
p = lambda t: B(t) @ coefficients.T

# Wartości wielomianu na przedziale [1900, 1990] w odstępach jednorocznych
all_years = np.arange(1900, 1991)
interpolated_population = np.array([p(x) for x in all_years])
```

Wykres:

```
[ ]: plt.figure(figsize=(10, 6))
plt.plot(years, population, 'ro', label='Węzły interpolacji')
plt.plot(all_years, interpolated_population, label='Wielomian interpolacyjny')
plt.xlabel('Rok')
plt.ylabel('Populacja')
plt.title('Interpolacja populacji Stanów Zjednoczonych')
plt.legend()
plt.grid(True)
plt.show()
```



Wyliczenie ekstrapolacji wielomianu i błędu względnego dla 1990 roku:

```
[ ]: extrapolated_population = p(1990)
true_value_1990 = 248709873
error = abs(extrapolated_population - true_value_1990) / true_value_1990 * 100

print("Wartość ekstrapolowana dla roku 1990:", round(extrapolated_population,2))
print("Prawdziwa wartość dla roku 1990:", true_value_1990)
print("Błąd względny ekstrapolacji dla roku 1990:", round(error,2), "%")
```

Wartość ekstrapolowana dla roku 1990: 82749141.0

Prawdziwa wartość dla roku 1990: 248709873

Błąd względny ekstrapolacji dla roku 1990: 66.73 %

Wyliczenie wielomianu interpolacyjnego Lagrange'a:

$$\ell_j(t) = \frac{\prod_{k=1, k \neq j}^n (t - t_k)}{\prod_{k=1, k \neq j}^n (t_j - t_k)} \quad j = 1, \dots, n$$


$$\ell_j(t_i) = \begin{cases} 1 & \text{if } i = j \\ 0 & \text{if } i \neq j \end{cases}, \quad i, j = 1, \dots, n$$

$$p_{n-1}(t) = y_1 \ell_1(t) + y_2 \ell_2(t) + \dots + y_n \ell_n(t)$$

```
[ ]: l = lambda t, j: np.prod(t-years[years!=years[j]])/np.prod(years[j]-years[years!=years[j]])
      p_lagerange = lambda t: np.sum([population[j] * l(t, j) for j in range(9)])
      interpolated_population_lagrange = np.array([p_lagerange(t) for t in all_years])
```

Wykres:

```
[ ]: plt.figure(figsize=(10, 6))
      plt.plot(years, population, 'ro', label='Węzły interpolacji')
      plt.plot(all_years, interpolated_population_lagrange, label='Wielomian_
      ↪interpolacyjny')
      plt.xlabel('Rok')
      plt.ylabel('Populacja')
      plt.title('Interpolacja Lagrange populacji Stanów Zjednoczonych')
      plt.legend()
      plt.grid(True)
      plt.show()
```



Wyliczenie wielomianu interpolacyjnego Newtona:

$$\pi_j(t) = \prod_{k=1}^{j-1} (t - t_k) \quad j = 1, \dots, n$$

$$\pi_j(t_i) = 0 \quad \text{for } i < j$$

$$\begin{aligned} p_{n-1}(t) &= x_1 \pi_1(t) + x_2 \pi_2(t) + \dots + x_n \pi_n(t) \\ &= x_1 + x_2(t - t_1) + x_3(t - t_1)(t - t_2) + \dots \\ &\quad + x_n(t - t_1)(t - t_2) \dots (t - t_{n-1}) \end{aligned}$$

```
[ ]: l_n = lambda t, j: np.prod(t-years[years<years[j]])
```

```
def x(i, j):
    if i == j: return population[i]
```

```

    return (x(i+1, j) - x(i, j-1))/(years[j] - years[i])

X = [x(0, i) for i in range(9)]
p_n = lambda t: np.sum([X[j] * l_n(t, j) for j in range(9)])

def horner(base, coefficients):
    n = len(coefficients) - 1
    W = coefficients[-1]
    for i in range(n-1, -1, -1):
        W = W*base[i] + coefficients[i]
    return W

interpolated_population_newton = np.array([p_n(t) for t in all_years])


```

Wykres:

```

[ ]: plt.figure(figsize=(10, 6))
plt.plot(years, population, 'ro', label='Węzły interpolacji')
plt.plot(all_years, interpolated_population_newton, label='Wielomian_
↪interpolacyjny')
plt.xlabel('Rok')
plt.ylabel('Populacja')
plt.title('Interpolacja Newtona populacji Stanów Zjednoczonych')
plt.legend()
plt.grid(True)
plt.show()

```



Wyliczenie wielomianu interpolacyjnego dla danych zaokrąglonych:


```
[ ]: population_rounded = np.round(population / 1e6) * 1e6
      print(population_rounded)
      coefficients_rounded = np.linalg.solve(best_V, population_rounded)

      p_rounded = lambda t: B(t) @ coefficients.T
      interpolated_population_rounded = np.array([p_rounded(x) for x in all_years])
```


```
[7.60e+07 9.20e+07 1.06e+08 1.23e+08 1.32e+08 1.51e+08 1.79e+08 2.03e+08
 2.27e+08]
```

Wykres:

```
[ ]: plt.figure(figsize=(10, 6))
      plt.plot(years, population_rounded, 'ro', label='Węzły interpolacji')
      plt.plot(all_years, interpolated_population_rounded, label='Wielomian
      ↪interpolacyjny')
      plt.xlabel('Rok')
      plt.ylabel('Populacja')
      plt.title('Interpolacja populacji Stanów Zjednoczonych dla danych
      ↪zaokrąglonych')
      plt.legend()
      plt.grid(True)
      plt.show()
```




```
[ ]: plt.figure(figsize=(10, 6))
plt.plot(years, population, 'ro', label='Węzły interpolacji')
plt.plot(all_years, interpolated_population, label='Wielomian interpolacyjny', )
plt.plot(all_years, interpolated_population_lagrange, label='Wielomian
↪interpolacyjny Lagrange',linestyle = 'dashed')
plt.plot(all_years, interpolated_population_newton, label='Wielomian
↪interpolacyjny Newtona',linestyle = 'dotted')
plt.xlabel('Rok')
plt.ylabel('Populacja')
plt.title('Interpolacja populacji Stanów Zjednoczonych')
plt.legend()
plt.grid(True)
plt.show()
```



Porównanie współczynników wielomianów interpolacyjnych dla danych zwykłych i zaokrąglonych:

```
[ ]: abs_coefficients_difference = np.abs(coefficients_rounded - coefficients)
print("Oryginalne współczynniki: ", coefficients,"\n")
print("Współczynniki dla danych zaokrąglonych: ", coefficients_rounded,"\n")
print("Wartość bezwzględna różnicy współczynników: ",
↪abs_coefficients_difference)
```

Oryginalne współczynniki: [1.32164569e+08 4.61307656e+07 1.02716315e+08
1.82527130e+08
-3.74614715e+08 -3.42668456e+08 6.06291250e+08 1.89175576e+08
-3.15180235e+08]

Współczynniki dla danych zaokrąglonych: [1.32000000e+08 4.59571429e+07
1.00141270e+08 1.81111111e+08
-3.56755556e+08 -3.38488889e+08 5.70311111e+08 1.86920635e+08
-2.94196825e+08]


Wartość bezwzględna różnicy współczynników: [164569.00000003
173622.71904778 2575044.9444446 1416019.06666657
17859159.33333355 4179566.93333346 35980138.66666675 2254940.6476191
20983409.77777779]

Porównanie wartości wielomianów interpolacyjnych dla Lagrange'a i Newtona:

```
[ ]: polynomial_difference_newton = np.abs(interpolated_population -  
      ↪interpolated_population_newton)  
polynomial_difference_lagrange = np.abs(interpolated_population -  
      ↪interpolated_population_lagrange)
```

2.1.2 Wykres błędu bezwzględnego wielomianów interpolacyjnych dla Lagrangea i Newtona

```
[ ]: plt.figure(figsize=(10, 6))  
plt.plot(all_years, polynomial_difference_newton, label='Wielomian_  
      ↪interpolacyjny Newtona')  
plt.plot(all_years, polynomial_difference_lagrange, label='Wielomian_  
      ↪interpolacyjny Lagrange')  
plt.xlabel('Rok')  
plt.ylabel('Różnica')  
plt.title('Błąd bezwzględny wielomianów interpolacyjnych dla Lagrangea i_  
      ↪Newtona')  
plt.legend()  
plt.grid(True)  
plt.show()
```



2.2 Wnioski

Analizując wykresy obliczonych wielomianów interpolacyjnych można wysnuć wniosek, że każdy z wielomianów daje niemal identyczne wyniki. Po wyliczeniu wartości bezwzględnej z różnicy wartości tych wielomianów w poszczególnych latach dla Lagrange'a i Newtona można zauważyć, że wartości różnią się lecz bardzo nieznacznie.

Ekstrapolacja wielomianu dla roku 1990 znacznie odbiega od faktycznej liczebności populacji w tym czasie, a błąd względny jest zdecydowanie za duży. Świadczy to o tym, że predykcje liczebności za pomocą wyliczonego wielomianu interpolacyjnego będą niepoprawne.

Po zaokrągleniu danych opisujących liczebność populacji współczynniki różnią się od tych wyliczonych dla danych bardziej dokładnych, jednak w tym przypadku nie wpływa to na wynik.

2.3 Bibliografia

https://heath.cs.illinois.edu/scicomp/notes/cs450_chapt07.pdf

https://math.libretexts.org/Courses/Angelo_State_University/Mathematical_Computing_with_Python/3%3A

prezentacja Interpolation Marcin Kuta